УДК 004.823

АВТОМАТИЗАЦИЯ РАСПОЗНАВАНИЯ ВНЕШНЕГО ВИДА ЧЕЛОВЕКА ПО ТЕКСТУ НА ЕСТЕСТВЕННОМ ЯЗЫКЕ И СИНТЕЗ ПОРТРЕТНОГО ИЗОБРАЖЕНИЯ

Орлова Ю.А., Долбин А.В., Кипаева Е.В.

Волгоградский государственный технический университет, г. Волгоград, Россия yulia.orlova@gmail.com

Данная статья посвящена разработке приложения по выделению элементов внешнего описания человека на основе текста. В статье описана модель внешнего вида человека, а также основные методы поиска внешности. Кратко описываются принципы построения фотороботов по текстовому описанию.

Ключевые слова: обработка текста; информационный поиск; латентно-семантический анализ; оценка релевантности; портретная идентификация; технология построения фоторобота.

Введение

Анализ текстовой информации для последующего синтеза некоторого изображения относится к сложным задачам и в большинстве случаев требует индивидуального решения. В данном проекте мы решили объединить две ведущиеся нами разработки: выявление внешнего вида человека из текста и синтез фоторобота по текстовому описанию.

На вход модуля выявления внешнего вида человека по тексту подается текст на русском языке в произвольной форме. Выходом является фрейм-экземпляр внешнего вида человека. Так как, объем входных данных может быть очень большим, то необходимо обеспечить максимальную производительность программы. Для обеспечения должного уровня быстродействия необходимо формировать инвертированной индекс входных данных [Дмитриев и др., 2013].

На вход модуля построения фоторобота подается полученный фрейм, выходом является синтезированное изображение.

1. Алгоритм выявления описания внешнего вида человека

Общий алгоритм выявления описания следующий:

- 1) графематический анализ текста;
- 2) морфологический анализ;
- 3) поиск упоминаний о личности в тексте;
- 4) применение латентно-семантического анализа

для установления зависимостей между ключевыми параметрами внешнего вида человека и множеством предложений;

5) выделение в предложении элементов внешнего вида человека.

Выделение предложений из сплошного текста – процедура необходимая для дальнейшего анализа текста в любой системе анализа естественных языков. Для решения данной задачи необходимо провести графематический анализ текста. [Солошенко и др., 2014а] Графематический анализ проводится в два этапа:

- 1) Выделение предложений из текста на основе поиска стоп-слов. В ходе разработки были выделены следующие стоп-символы: «.», «!», «;», «?»
- 2) Выделение отдельных слов в полученных предложениях.

Задачей морфологического разбора является описание морфологической формы слова и её синтаксической роли в предложении [Солошенко и др., 2014а; Солошенко и др., 2014b]. Как правило, анализу подвергаются слова в контексте предложения, но в данном проекте был принят ряд допущений:

- 1) Входной текст должен быть только на русском языке.
- 2) Входной текст не должен содержать какихлибо грамматический или синтаксических ошибок.
- 3) Букву «ё» не следует заменять буквой «е», так как это приведет к неправильному морфологическому анализу слова.

4) Упрощенный разбор «двусмысленных предложений».

2. Модель внешнего вида человека

Был произведен анализ важных элементов описания внешнего вида человека для разных профессий: художник, писатель, криминалист, скульптор. В итоге была составлена информационная модель в виде фрейма-прототипа на языке frame represenation language:

(frame Внешний_Вид (Poct (value(M)) (IF NEEDED(ph s)) (Телосложение (value(M)) (IF_NEEDED(ph_s)) (Голова (value(M)) (IF_NEEDED(ph_s)) (Волосы (value(M)) (IF NEEDED(ph s)) (Лицо (value(M)) (IF_NEEDED(ph_s)) (Лоб (value(M)) (IF_NEEDED(ph_s)) (Брови (value(M)) (IF NEEDED(ph s)) (Глаза (value(M)) (IF_NEEDED(ph_s)) (Pесницы (value(M)) (IF NEEDED(ph s)) (Hoc (value(M)) (IF NEEDED(ph s)) (Уши (value(M)) (IF_NEEDED(ph_s)) (Губы (value(M)) (IF_NEEDED(ph_s)) (Подбородок (value(M)) (IF NEEDED(ph s)) (Зубы (value(M)) (IF NEEDED(ph s)) (Шея (value(M)) (IF NEEDED(ph s)) (Плечи (value(M)) (IF NEEDED(ph s)))

Здесь М – множество внешних характеристик, а ph_s — демон поиска заранее заданных фразеологизмов. Изначально планировалось задать фиксированный набор элементов описания на каждый параметр внешнего вида. Но в ходе разработке от этой идее пришлось отказаться, так как каждый параметр может быть описан огромным множеством различных речевых оборотов. Поиск описания внешнего вида человека производится по морфологическим признакам [Баргесян, 2004].

В случае, когда один или несколько слотов фрейма остались незаполненными, отрабатывается процедура поиска фразеологизмов в тексте. Набор фразеологизмов для каждого слота задается в программе в графическом интерфейсе пользователя и сохраняется на жёстком диске в файле структуры xml. Фразеологизмы представляют продукционную модель знаний: <условие>, то <действие>. Применительно к рассматриваемой теме условие онжом сформулировать следующим образом: если <в данном предложении упоминается описание личности и встречается один из указанных фразеологизмов>, то <заполнить слот фрейма соответствующим значением>. Механизм работы с фразеологизмами был добавлен для случаев, когда разработанного функционала программы недостаточно для выполнения тех или иных операций.

3. Обзор корпусов русского языка и систем информационного поиска

Был проведен обзор корпусов и словарей русского языка. Список рассмотренных корпусов:

- Национальный корпус русского языка.
- Открытый корпус русского языка.
- Тюбингенский корпус.
- Хельсинскй аннотированный корпус.

В результате анализа был выбран открытый корпус русского языка, так как он удовлетворял ряду необходимых требований:

- Большое число словоупотреблений с морфологической разметкой.
 - Наличие подкорпуса со снятой омонимией.
 - Наличие частотных списков.
- Возможность использования на локальной машине.

Не смотря на то, что национальный корпус русского языка имеет больший объем, емкость открытого корпуса (более 200 млн. словоупотреблений) является вполне достаточным для решаемых задач.

Следующим шагом являлась разработка алгоритма по нахождению упоминаний личности в тексте. Был проведен анализ систем семантического анализа текста по критериям (таблица 1): не требует участия человека для формирования выборки (1), возможность выделения фактов из текста (2), построение семантической сети текста (3), выделения внешнего описания человека в тексте (4), учет сложных синтаксических конструкций текста (5).

- В результате сравнительного обзора были выявлены недостатки существующих на данный момент систем:
- 1) Требуется предварительная настройка или наличие обучающей выборки.
- 2) Представление результатов в неудобном и неструктурированном для пользователя виде.
- 3) Отсутствие сформированной информационной модели внешнего вида человека.

Чтобы решить недостатки 1, 2 были сделаны следующие допущения и ограничения на работу нашего алгоритма по нахождению упоминаний личности в тексте:

- 1) Отсутствие чётких правил для разрешения анафоры местоимений третьего лица.
- 2) Во входном тексте должна упоминаться только одна личность.

Таблица 1 – Сравнительный обзор систем семантического анализа текста

	1	2	3	4	5
Томита- парсер	-	+	+	+	+
(Yandex)					
AOT					
(www.aot.r	+	-	+	-	-
u)					
Fact					
extractor	_	+	+	+	_
desktop		'		'	
(RCO)					
Поиско-					
вые					
системы	+	+	+	+	-
(google.					
com)					
Semantix					
(Синерге-	_	_	+	_	_
тические			,		
системы)					

Индексация предложений с описанием человека проходит в два этапа. На первом этапе проводится лемматизация слов и нахождение ФИО человека. На втором этапе проводится поиск местоимений, согласуются по морфологическим которые признакам. Простота такого подхода и принятые допущения безусловно снижают универсальность и качество получаемых результатов, однако мы планируем исправить усовершенствовать и алгоритм.

4. Латентно-семантический анализ

В качестве индексирования текста на естественном языке применялся метод латентносемантического анализа [Стенин, 2013].

Минусы латентно-семантического анализа:

- Скорость работы данного метода значительно ухудшается при увеличении объема входных документов.
- Латентно-семантический анализ не учитывается контекст документа.

Положительные стороны применения латентносемантического анализа:

- Частичное снятие омонимии с индексируемых слов.
- В работе метода используются матрицы, которые являются результатом сингулярного разложения частотной матрицы.

Реализованный алгоритм работы латентносемантического анализа, выводом которого является векторное пространство текста:

- 1) По входному тексту посчитать количество вхождений каждого слова в каждое предложение. Составить частотную матрицу.
- 2) Применение оценки релевантности полученных результатов методом TF-IDF над частотной матрицей. TF-IDF является методом

взвешивания на основе комбинации частоты и обратной документной частоты [Маннинг, 2011].

- 3) Использование сингулярного разложения над матрицей, полученной на втором этапе, для формирования матриц U, S, Vt, где U пространство документов, Vt пространство слов, S диагональная матрица.
- 4) Для матрицы Vt в дальнейшей работе метода не учитываются строки с индексом больше 2, а для матрицы U столбцы с индексом больше 2.
- 5) Определить индекс слота фрейма относительно остальных слов.
- 6) По матрицам Vt, U определить координаты ключевого параметра внешнего вида человека и всех документов.

Особенность сингулярного разложения матрицы в том, что оно выделяет ключевые составляющие матрицы, позволяя игнорировать шумы.

Алгоритм сингулярного разложения матрицы:

1) Пусть дана частотная матрица А. Тогда необходимо вычислить матрицу по формуле:

$$B = A^t * A. (1)$$

2) Построить уравнение:

$$det(B - \lambda * E) = 0. \tag{2}$$

3) Если n – размерность матрицы, то получаем степенное уравнение вида:

$$a_0 \lambda^n + a_0 \lambda^{n-1} + \dots = 0.$$
 (3)

4) Если V — искомый собственный вектор, то найти собственные вектора можно следующим образом:

$$det(B - \lambda * E)V = 0. \tag{4}$$

- 5) Точно также найти все собственные векторы, из которых сформировать матрицу U.
- 6) Сформировать матрицу S из корней собственных чисел, расположенных по диагонали.
- 7) Рассчитать заключительную матрицу V по формуле:

$$V^t = S^{-1}U^t A. (5)$$

5. Определение элементов внешнего вида

Основная идея заключается в том, чтобы по морфологическим признакам определить качества, которые относятся к тем или иным слотам фрейма. В каждом индексированном предложении с найденным упоминанием о внешнем виде человека определяется позиция самого объекта и внешней характеристики. Если два слова расположены близко и совпадают по морфологическим признакам, то заполнить слот фрейма. На данный момент отбор происходит исключительно по прилагательным, характеризующими качество объекта.

6. Фоторобот

Наука об описании человеческого лица и построении фоторобота называется габитоскопией. Портретная криминалистическая экспертиза является одной ИЗ форм портретной идентификации. Принцип фоторобота кардинально отличен от принципов живописного портрета или фотографии. Фоторобот составляется из фрагментов множества иных, неидентичных искомому лиц, через сведение отдельных типических черт и черточек (элементарных частиц человеческого облика).

В практике криминалистов фоторобот призван дать не точное изображение лица прототипа, но максимальное приближение к тому впечатлению от лица, которое сложилось в памяти очевидца. Таким образом в отличие от фотографии (дающей мгновенный объективный слепок лица) и от портрета (где художник как будто нарочно умерщвляет лицо своей "модели", превращая само изображение В "модель восприятия") фоторобот есть не что иное как неотрывное от воспринимающего субъекта-автора запечатление живого лица, лица из жизни, лица, проплывающего мимо нас в потоке времени. Это изменчивое лицо живого существа - открытое ко времени и ко множеству взглядов.

7. Системы построения фоторобота

Было проведен обзор и сравнение систем для построения фоторобота.

Программа Faces содержит более 9000 особенностей строения человеческого лица. Все отобранные части лица соединяются в единое целое, в результате чего получается фотография человека. Также в редакторе имеются возможности коррекции тона волос и внесение различных дополнений, таких как пирсинг, тату и т.п. Конечный результат - составленный со слов очевидца фоторобот - мало чем отличается от фотографии. В процессе составления фоторобота генерируется его уникальный код, по которому на любом рабочем месте может быть сгенерирован требуемый фоторобот (рисунок 1).

«Каскад-Фоторобот» предназначен автоматизации процесса составления портрета лиц мужского и женского пола, монголоидной и европеоидной расы, в профиль и анфас. В данном программном продукте присутствуют такие дополнительные возможности, как: коррекция элементов внешности (масштабирование, поворот, трансформирование); свободное дорисовка индивидуальных особенностей в ручном режиме (инструменты «кисть», «карандаш», «ластик», «аэрограф», «палец»); подготовка нескольких вариантов изображения одного человека (рисунок 2).

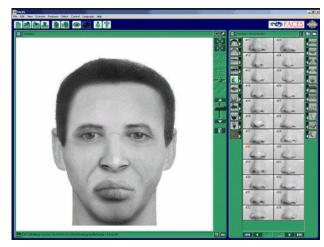


Рисунок 1 – Пример работы программы Faces 4.0

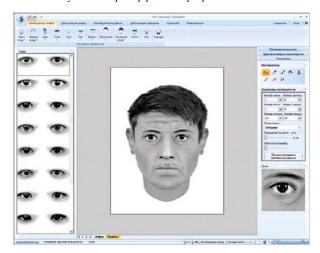


Рисунок 2 – Интерфейс программы «Каскад-Фоторобот»

3D Фоторобот (3DHead) — это система предназначена для оперативной портретной идентификации (т.е. для построения портрета человека по памяти с целью идентификации), однако может быть использована не только правоохранительными органами для проведения розыскных мероприятий, но и в любых других областях, где требуется создание трехмерных моделей головы человека.

Традиционно программы этого класса представлены в виде библиотек готовых элементов лица, перебором которых нужно собрать образ, максимально приближенный к оригиналу. Эффективность их не высокая, так как для создания качественного образа нужны большие библиотеки, в которых трудно найти подходящий рисунок (рисунок 3).

В этой системе использован другой подход — создана математическая модель головы человека, изменяя параметры которой можно получить практически любой тип лица и головы человека. То есть не нужно выискивать в списках похожий элемент лица — нужно только изменить связанные с этим элементом параметры модели, причем пересчет модели производится в реальном времени, по мере изменения любого параметра одновременно изменяется и образ на экране.

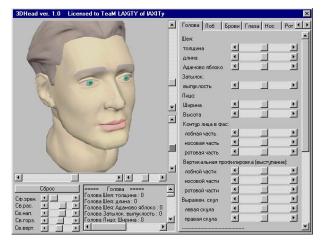


Рисунок 3 – Пример работы программы 3D Head

Однако, у программы существует несколько серьезных недостатков. Крайне сложный интерфейс, внушительная ресурсоемкость и самое длительное время построения фоторобота среди всех рассмотренных аналогов.

8. Синтез портретного изображения

В компьютерной графике давно известна и используется технология морфинга, позволяющая получать "среднее арифметическое" несколькими изображениями. Если использовать её объединения нескольких фотороботов, для изображения узнаваемость итогового заметно повышается. Морфинг может применяться и создании непосредственно при фотороботов. Корректируя фоторобот с его помощью, можно добиться большего соответствия итогового изображения, чем при "сборке" лица из готовых частей, применяемой сейчас [Michael, 2008].

Для избавления от случайных шумов изображении будет использоваться метол сглаживания. Сглаживание или анти-алиасинг является процессом, который пытается минимизировать появление ступенчатых зубчатых диагональных границ, которые придают тексту или изображениям грубый цифровой вид [Норвиг, 2006]. Сглаживание удаляет эти ступеньки и создаёт впечатление более мягких границ и высокого разрешения. Оно принимает во внимание, насколько идеальная граница перекрывает смежные пиксели. Ступенчатая граница просто округлена вверх или вниз без промежуточного значения, тогда граница выдаёт сглаженная значение, пропорциональное TOMY, насколько много границы попало в каждый пиксель (рисунок 4).

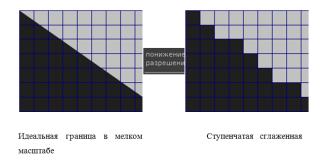


Рисунок 4 – Границы изображения

Для реализации программы была собрана база данных изображений с частями лица. Каждое такое изображение было проиндексировано и отмечено к какой части головы оно относится.

Общий принцип работы программы, построенной по принципу многокомпонентного программного обеспечения [Заболеева-Зотова и др.. 2013], заключается в следующем: пользователь вводит текстовое описание человека или подгружает его. Текст анализируется, формируется фрейм-По нему максимально близко экземпляр. выбирается После изображение. чего набор изображений компонуется в одно изображение (рисунок 5).

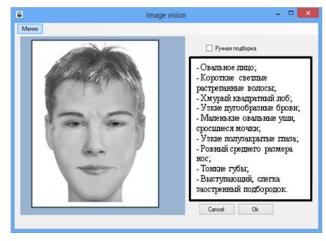


Рисунок 5 — Пример работы программы разрабатываемой системы

Также в данном программном продукте имеется возможность подобрать описание частей лица и вручную настроить их размеры (рисунок 5).

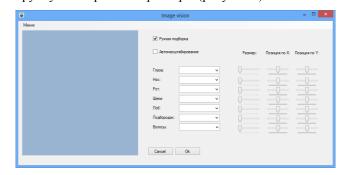


Рисунок 6 – Интерфейс программного продукта при ручном подборе описания человека

Заключение

В результате была разработана программа на языке Python 3.3 с использованием библиотеки морфологического анализа pymorphy2, выделяющая из текста внешнее описание человека разработанным в ходе работы над проектом алгоритмами. Результаты показывают высокую точность распознавания. В ходе дальнейшей работы решить следующие проблемы: разрешение омонимии на основе контекстных правил. использование семантического синтаксического анализа языковых конструкция, улучшение алгоритма поиска личности, улучшение алгоритма разрешения анафоры. Синтез изображения и его коррекция может быть проведена с учетом работ [Розалиев и др., 2010; Бобков и др., 2011]. Создание фоторобота человека играет важную роль не только в криминалистике, но и в сферах жизни. Благодаря предлагаемой системе пользователю не надо будет делить лицо на несколько частей, чтобы составить фоторобот, ему следует просто представить описание человека, которого он видел, достаточно упростит задачу.

Работа частично поддержана Российским фондом фундаментальных исследований (проекты 13-07-00351, 13-07-97042, 14-07-97016, 14-07-97017, 15-07-06322, 15-07-05440).

Библиографический список

[Баргесян, 2004] Методы и модели анализа данных ОLАР и Data Mining / А. А. Баргесян [и др.]. — Спб.: БХВ-Петербург, 2004 — 336 с.

[Бобков и др., 2011] Развитие системы автоматизированного определения эмоций и возможные сферы применения / Бобков А.С., Заболеева-Зотова А.В., Орлова Ю.А., Розалиев В.Л. // Открытое образование. - 2011. - № 2. - С. 59-62.

[Дмитриев и др., 2013] Automatic identification of time and space categories in the natural language text / Дмитриев А.С., Заболеева-Зотова А.В., Орлова Ю.А., Розалиев В.Л. // Applied Computing 2013: proceedings of the IADIS International Conference (Fort Worth, Texas, USA, October 23-25, 2013) / IADIS (International Association for Development of the Information Society), UNT (University of North Texas). – [Fort Worth (Texas, USA)], 2013. – P. 187-190.

[Заболеева-Зотова и др., 2013] Formalization of initial stage of designing multi-component software / Заболеева-Зотова А.В., Орлова Ю.А., Розалиев В.Л., Фоменков С.А., Петровский А.Б. // Multi Conference on Computer Science and Information Systems 2013 (Prague, Czech Republic, July 23-26, 2013): Proceedings of the IADIS International Conference Intelligent Systems and Agents 2013 / IADIS (International Association for Development of the Information Society). – [Prague], 2013. – P. 107-111.

[Маннинг, 2011] Маннинг, К. Д. Введение в информационный поиск / К. Д. Маннинг, П. Рагхаван, Х. Шютце; пер. с англ. под ред. П. И. Браславского, Д. А. Клюшина, И. В. Сегаловича. - Москва.: И. Д. Вильямс, 2011. — 528 с.

[Морозов и др., 2010] Морозов, Д.А. Обработка растровых изображений с помощью Грид-технологии / Морозов Д.А., Стуров Д.А. // Алгоритмы, методы и системы обработки данных : сб. науч. тр. Вып. 15 / Муромский ин-т (филиал) ГОУ ВПО "Владимирский гос. ун-т". - Муром, 2010.

[Норвиг, 2006] Норвиг П., Искусственный интеллект. Современный подход. – М.: ВИЛЬЯМС, 2006.

[Розалиев и др., 2010] В.Л. Розалиев, А.С. Бобков, О.С. Федоров Применение нейронных сетей и грануляции при построении автоматизированной системы определения эмоциональных реакций человека / Изв. ВолгГТУ. Серия «Актуальные проблемы управления, вычислительной техники и

информатики в технических системах»: межвуз. сб. науч. ст. / ВолгГТУ. - Волгоград, 2010. - Вып. 9, № 11. - С. 63-68.

[Стенин, 2013] Латентно-семантический метод извлечения информации из интернет ресурсов / А. А. Стенин [и др.] // Восточно-Европейский журнал передовых технологий. Автоматика. Вычислительная техника. — 2013. — Вып. 9, Том 4. — С. 19-22.

[Солошенко и др., 2014a] Thematic Clustering Methods Applied to News Texts Analysis / Солошенко А.Н., Орлова Ю.А., Розалиев В.Л., Заболеева-Зотова А.В. // Knowledge-Based Software Engineering: Proceedings of 11th Joint Conference, JCKBSE 2014 (Volgograd, Russia, September 17-20, 2014) / ed. by A. Kravets, M. Shcherbakov, M. Kultsova, Tadashi Iijima; Volgograd State Technical University [etc.]. – [Б/м]: Springer International Publishing, 2014. – P. 294-310. – (Series: Communications in Computer and Information Science; Vol. 466).

[Солошенко и др., 2014b] Автоматизация семантического анализа новостных Интернет-текстов. / Солошенко А.Н., Розалиев В.Л., Орлова, Ю.А. // Открытые семантические технологии проектирования интеллектуальных систем OSTIS-2014: матер. IV междунар. науч.-техн. конф. (Минск, 20-22 февр. 2014 г.). Белорус. гос. ун-т информатики и радиоэлектроники, Администрация Парка высоких технологий. Минск, с. 435-438.

[Ужва, 2013] Ужва А.Ю. Автоматизированная разработка онтологической модели предметной области для поиска образовательных ресурсов с использованием анализа текстов рабочих программ // Современные проблемы науки и образования. – Волгоград, 2013.

[Michael, 2008] Michael L. Matthews: Discrimination of Identikit constructions of faces: Evidence for a dual processing strategy / Michael L. // Perception & Psychophysics, March 2008, Volume 23, Issue 2, pp 153-161.

AUTOMATED RECOGNITION OF THE APPEARANCE OF MAN ON THE NATURAL LANGUAGE AND SYNTHESIS OF PORTRAIT IMAGES

Orlova Yu.A., Doldin A.V., Kipaeva E.V.

Volgograd State Technical University, Volgograd, Russia

yulia.orlova@gmail.com

This article is devoted to the development application for the allocation of items to the external description of a person on the basis of the text.

The article describes the model of the appearance of a person, as well as the main methods of searching appearance. Briefly describe the principles of composite on a text description.

This paper describes the concept and principle of the identikit. Also examined existing systems and methods for constructing composite picture. On the basis of the study proposes the creation of a new system for the identification of human portraiture text description. Creating a composite sketch of a man playing an important role not only in criminology, but also in other areas of life. With the new proposed system, the user will not have to divide the face into several pieces to make an identikit, he should simply provide a description of the man whom he had seen enough to make it easier.

Keywords: text processing; information retrieval; latent semantic analysis; assessment of relevance; portrait identification; technology building sketch.